

Sistema de Predicción de Riesgo Socioeconómico Cantonal

Índice de Riesgo Socioeconómico (IRS) e Índice de Resiliencia Local (IRL)

Desarrollado por	■ Evelyn Dayana Oña Guallichico ■ Yoslava Jhesire Garófalo Jiménez ■ Alisson Marisol Manosalvas Morales ■ Juan Sebastian Ramos Obaco ■ Kevin Gustavo Delgado Cuchala	Dirigido a	GAD Provinciales y Cantonales del Ecuador
Tipo de modelo	Regresión / Series de tiempo (supervisado)	Dominio	Economía territorial / Política pública
Cobertura	219 cantones · 2019–2024	Estado	Modelos base (baseline) — no productivo

Este documento describe un conjunto de **modelos base (baseline)** diseñados para estimar y proyectar el **Índice de Riesgo Socioeconómico (IRS)** a escala cantonal en Ecuador, como insumo para la asignación presupuestaria y la focalización de política pública por parte de los Gobiernos Autónomos Descentralizados (GAD). El IRS es un *proxy* de la probabilidad de pobreza estructural construido a partir de registros administrativos oficiales (INEC, SRI, SCVS, BCE). Sobre el IRS se deriva el KPI de negocio **IRL (Índice de Resiliencia Local)**, que compara la dinámica de cada cantón frente al promedio nacional. El model card detalla los datos, la metodología, las métricas de validación y —de forma central— las **limitaciones y riesgos** que condicionan un uso responsable.

1. Detalles del modelo

El sistema integra una arquitectura predictiva de convergencia metodológica: combina un modelo econométrico de series de tiempo con dos algoritmos de aprendizaje automático basados en árboles. El objetivo es estimar el IRS de cada cantón para los años 2025 y 2026, capturando tanto la inercia temporal del indicador como las interacciones no lineales entre las variables socioeconómicas.

Atributo	Descripción
Nombre del sistema	Sistema de Predicción de Riesgo Socioeconómico Cantonal (Dashboard IRL + Modelos ML)
Variable objetivo	Índice de Riesgo Socioeconómico (IRS), normalizado en el rango [0, 1]
Modelos evaluados	(1) Series de Tiempo: Tendencia Lineal y variantes Autorregresivas AR(1) y AR(2); (2) Random Forest Regressor; (3) Gradient Boosting / XGBoost Regressor
Modelo ganador	TS2 — AR(1) + Tendencia Lineal (menor RMSE en validación 2024)

Features de entrada	Año, Cantón (codificado), variación interanual real de la producción per cápita (var_pc), Log_Población, IRS rezagado 1 año (IRS_lag1) y 2 años (IRS_lag2)
Librerías	Python 3.12 · scikit-learn · XGBoost · pandas · numpy · Prophet/ARIMA (prospectivo)
Infraestructura	Google Colab / GCP (cómputo) · GitHub (control de versiones)
Tipo de aprendizaje	Supervisado (regresión), con validación temporal Time Series Split
Versión / fecha	1.0 — Junio 2026

2. Uso previsto

Usos apropiados

- Apoyar la **focalización presupuestaria** de los GAD identificando cantones rezagados ($IRL \leq 0$) frente a la dinámica nacional.
- Servir como herramienta de **alerta temprana**: el IRL funciona como semáforo rápido para priorizar intervención ($IRL \leq 0$) o asignar prioridad baja ($IRL > 0$).
- Aportar **benchmarking cantonal** comparable a nivel nacional ante la ausencia de mediciones censales directas en el periodo.
- Alimentar un **dashboard exploratorio** de tendencias de empleo, salarios, ventas, recaudación y riesgo por cantón, provincia y año.

Usuarios previstos

- **Primario**: planificadores y directores de desarrollo económico de los 24 GAD Provinciales.
- **Secundario**: alcaldías de los 219 GAD Cantonales que requieren benchmarking.
- **Terciario**: Ministerio de Economía / SENPLADES, para evaluación de impacto de programas a escala cantonal.

Usos fuera de alcance (no recomendados)

- Tomar el IRS como una **medición oficial de pobreza**: es un índice sintético *proxy*, no un dato censal ni una tasa de pobreza monetaria.
- Asignar recursos a una persona u hogar individual: el modelo opera a nivel **agregado cantonal**, no individual (riesgo de falacia ecológica).
- Usar las proyecciones 2025–2026 como pronóstico de alta precisión sin **intervalos de incertidumbre** ni revalidación con datos observados.
- Aplicarlo a los cantones excluidos del entrenamiento (zonas no delimitadas) o extrapolar fuera del rango 2019–2024.
- Sustituir el juicio técnico-político: las salidas son un **insumo de apoyo**, no una decisión automatizada.

3. Datos de entrenamiento

El dataset proviene del procesamiento de más de 230 bases de microdatos de registros administrativos oficiales (cada una con ~4 millones de registros individuales), depuradas y consolidadas en Stata 18 y armonizadas como series de tiempo cantonales. La construcción fue un trabajo conjunto del Observatorio de la Política Económica y Competitividad (OPEC) de la Universidad Agraria del Ecuador y el Centro de Estudios Económicos para el Desarrollo del Ecuador (CEEDE).

Fuentes y cobertura por indicador

Indicador	Unidad	Fuente	Periodo
Empleo registrado (IESS)	N.º trabajadores	INEC	2009–2024
Salario promedio (IESS)	USD corrientes	INEC	2009–2024
Recaudación tributaria	USD corrientes	SRI · INEC	2010–2024
Nuevas empresas	N.º empresas	SCVS	2014–2024
Ventas totales	USD corrientes	SRI · INEC	2017–2024
Población	N.º habitantes	BCE	2018–2023
VAB de producción per cápita	USD corrientes	BCE · INEC	2018–2023
VAB de producción	USD corrientes	BCE · INEC	2018–2023

Fuentes: INEC, Servicio de Rentas Internas (SRI), Superintendencia de Compañías, Valores y Seguros (SCVS) y Banco Central del Ecuador (BCE).

Dataset final de modelado

- **Cobertura del modelo:** 219 cantones, periodo 2019–2024 (los registros usados se restringen a este rango, donde concurren todas las variables económicas).
- **Volumen:** 1.326 registros tras limpieza (cantón × año).
- **Variables económicas base:** empleo, salario, ventas, recaudación, nuevas compañías, población, VAB per cápita y variación interanual real.
- **Variables derivadas:** Log_Población (logaritmo natural para estabilizar la asimetría) e IRS (variable objetivo).

Construcción de la variable objetivo (IRS)

El IRS se construyó en tres pasos: (1) se sintetizaron cinco variables de capacidad económica (empleo, salario, ventas, recaudación y nuevas compañías) en un único **Índice de Capacidad Económica** mediante Análisis de Componentes Principales (PCA, 1 componente) sobre datos estandarizados; (2) se invirtió su polaridad ($\times -1$) para convertir "capacidad" en "vulnerabilidad", siguiendo la premisa de la economía del desarrollo de relación negativa entre dinamismo productivo y pobreza (Sen, 1999); (3) se normalizó al rango [0, 1] con MinMax. El resultado es un *proxy* de probabilidad de pobreza estructural, comparable a nivel nacional.

4. Preprocesamiento y limpieza

Decisiones de limpieza

- **Exclusión de zonas no delimitadas:** se eliminaron los cantones El Piedrero y Manga del Cura, territorios históricamente en disputa sin estructura de GAD municipal. Sus nulos en recaudación y registro mercantil son **estructurales** (no aleatorios); imputarlos habría sesgado el modelo. Representaban <1% de los datos.
- **Imputación de 2024:** población, VAB per cápita y variación interanual de 2024 se imputaron mediante **regresión lineal por cantón** (no por promedios globales), preservando la trayectoria individual de cada territorio.
- **Estandarización de texto:** se aplicó strip a campos de cantón y provincia y redondeo a 2 decimales en numéricos.
- **Verificación final:** el dataset quedó libre de valores nulos antes del modelado.

Análisis de outliers (regla IQR 1.5×)

Se detectaron y reportaron valores atípicos por variable, sin eliminarlos automáticamente, reconociendo que reflejan la heterogeneidad real entre cantones grandes y pequeños. La concentración de outliers es alta en variables de escala (ventas, recaudación), lo que motivó transformaciones logarítmicas para la población.

Variable	Mediana	Media	Outliers	% del total
Ventas locales	66.3 M	954.5 M	174	13.12 %
Recaudación tributaria	1.82 M	71.9 M	189	14.25 %
Población	27 025	79 940	115	8.67 %
Nuevas compañías	8.0	73.5	163	12.29 %
VAB per cápita	2 467	4 785	165	12.44 %
Variación interanual real	2.67	3.26	47	3.54 %

Outliers detectados mediante la regla $1.5 \times IQR$ sobre el dataset limpio (1.326 registros).

5. Metodología de modelado

Estrategia de validación

Se aplicó una validación temporal tipo Time Series Split, respetando el orden cronológico: entrenamiento con el periodo 2019–2023 y validación contra el año 2024. Para los modelos de ML se usaron variables de rezago (IRS_lag1, IRS_lag2) construidas por cantón, lo que reduce el conjunto efectivo al descartar los primeros años sin historial. Esta validación previene el sobreajuste y evita la fuga de información del futuro hacia el pasado.

Modelos comparados

- **Series de tiempo (3 variantes):** TS1 (tendencia lineal pura), TS2 (AR(1) + tendencia) y TS3 (AR(2) + tendencia), implementadas como regresiones lineales sobre año, cantón y rezagos.
- **Random Forest:** 300 árboles, profundidad máxima 8, mínimo 3 muestras por hoja; capta interacciones no lineales rural/urbano.
- **Gradient Boosting / XGBoost:** 400 estimadores, learning rate 0.05, profundidad 4, submuestreo 0.8; minimización iterativa del error.

6. Métricas de desempeño

Resultados sobre el conjunto de validación (año 2024). Menor RMSE y MAE es mejor; mayor R2 es mejor. El modelo ganador se resalta en verde.

Modelo	RMSE ↓	MAE ↓	R ² ↑
TS1 — Tendencia Lineal	0.08129	0.02012	0.00508
TS2 — AR(1) + Tendencia ★	0.00351	0.00190	0.99814
TS3 — AR(2) + Tendencia	0.00811	0.00173	0.99011
Random Forest	0.01732	0.00274	0.95482
Gradient Boosting (XGBoost)	0.01327	0.00198	0.97350

Importancia de variables

En Random Forest, el **Log_Población** domina la importancia (0.577), seguido de los rezagos del IRS (0.212 y 0.211). En Gradient Boosting, el **IRS_lag1** es el predictor principal (0.495), seguido de Log_Población (0.349). En ambos casos, el año, el cantón codificado y la variación per cápita aportan poco. Esto confirma que el IRS tiene una **fuerte persistencia temporal**: el valor del año anterior es el mejor predictor del año siguiente, razón por la cual el modelo autorregresivo AR(1) resultó ganador.

Lectura crítica de los resultados

- El R2 de 0.998 del modelo ganador **no debe interpretarse como capacidad predictiva real de pobreza**: refleja sobre todo la autocorrelación del IRS (un índice que cambia lentamente año a año), no un descubrimiento causal.
- Como el IRS se deriva de las mismas variables económicas, predecirlo es en parte predecir su propia inercia. El desempeño alto es esperable y debe contextualizarse.
- Las proyecciones 2025–2026 se generan de forma recursiva (la predicción de 2025 alimenta el rezago de 2026), lo que **acumula error** en el segundo horizonte.

7. KPI de negocio — Índice de Resiliencia Local (IRL)

El IRL traduce las salidas del modelo en una métrica accionable para los GAD. Se define como la diferencia entre la variación real per cápita del cantón y el promedio nacional, funcionando como un semáforo de priorización presupuestaria.

IRL = Variación real p.c. del cantón – Promedio nacional

IRL > 0 → el cantón supera la dinámica nacional → **prioridad baja**

IRL ≤ 0 → el cantón está rezagado → **intervención prioritaria**

8. Limitaciones

- **IRS como proxy, no como medición directa.** El IRS es un índice sintético derivado de variables económicas vía PCA, no una tasa de pobreza oficial (monetaria o multidimensional). Su validez como medida de pobreza no ha sido contrastada contra encuestas como la ENEMDU.
- **Ventana temporal corta.** El modelado efectivo cubre apenas 2019–2024 (6 años). Con tan pocos puntos por cantón, los modelos autorregresivos tienen alto riesgo de capturar inercia en lugar de señal estructural, y AR(2) ya añade ruido.
- **Imputación que suaviza tendencias.** Los valores de 2024 (población, VAB) son imputados por regresión lineal, lo que asume continuidad de tendencias y puede ocultar choques económicos reales de ese año.
- **Periodo atípico (pandemia).** La ventana incluye 2020–2021, marcadas por la pandemia de COVID-19. Las relaciones aprendidas pueden estar distorsionadas por ese shock y no generalizar a años normales.
- **Heterogeneidad extrema entre cantones.** La presencia de 8–14% de outliers en variables clave indica que un modelo único trata por igual a cantones muy desiguales (p. ej. Guayaquil vs. cantones rurales pequeños).
- **Cantones excluidos sin cobertura.** El Piedrero y Manga del Cura quedan sin predicción; cualquier necesidad de política pública en esas zonas no está cubierta por el sistema.
- **Ausencia de intervalos de confianza.** Las proyecciones se entregan como puntos, sin cuantificación de incertidumbre, lo que puede transmitir una falsa sensación de precisión.
- **Error acumulado en horizonte 2026.** La proyección recursiva hace que el error de 2025 se propague a 2026, degradando la fiabilidad del segundo año.

9. Consideraciones éticas y de equidad

Riesgos de sesgo

- **Sesgo de cobertura administrativa:** el IRS depende de registros formales (IESS, SRI, SCVS). Cantones con alta **informalidad económica** pueden aparecer artificialmente como de mayor o menor riesgo, porque su actividad real no se refleja en los registros. Esto podría perjudicar precisamente a los territorios más vulnerables.
- **Sesgo de tamaño poblacional:** dado que Log_Población es la variable más influyente, existe el riesgo de que el índice capture más el **tamaño** del cantón que su nivel real de riesgo socioeconómico.
- **Falacia ecológica:** conclusiones a nivel cantonal no aplican a individuos u hogares dentro del cantón.
- **Riesgo de profecía autocumplida:** si la asignación presupuestaria se basa en el IRS y este se retroalimenta de variables económicas, podría reforzar desigualdades preexistentes si no se supervisa.

Recomendaciones de uso responsable

- Acompañar siempre el IRS/IRL con **indicadores oficiales complementarios** (NBI, pobreza por consumo, ENEMDU) antes de decidir.
- Mantener **supervisión humana** en toda asignación de recursos; el sistema es un insumo, no un decisor.
- Documentar y revisar periódicamente el desempeño por **grupos de cantones** (rural/urbano, grande/pequeño) para detectar desempeño desigual.
- Comunicar siempre la **incertidumbre** de las proyecciones a los tomadores de decisión.
- Reentrenar con datos oficiales nuevos del INEC y **revalidar** contra los años observados a medida que estén disponibles.

10. Mantenimiento y gobernanza

- **Reentrenamiento:** periódico, al publicarse nuevos datos del INEC y demás fuentes.
- **Reproducibilidad:** pipeline en Python versionado en GitHub (repositorio del equipo).
- **Monitoreo:** se recomienda comparar las proyecciones con los valores reales conforme se publiquen, registrando la deriva del modelo.
- **Contacto:** Equipo de Data Science — DATA Club ESPOL, con respaldo metodológico de ESPOL.