

DECISION LOG

Documentación del Ciclo de Vida del Modelo de Machine Learning

Proyecto Integrador

Predicción de Riesgo de Pobreza Cantonal en Ecuador

Equipo del Proyecto

Integrante	Rol	Responsabilidad Principal
Juan Ramos	Machine Learning Engineer	Automatización, modelos y arquitectura
Kevin Delgado	Data Engineer	ETL, limpieza y preprocesamiento
Yoslava Garofalo	Data Scientist	Experimentación, métricas y validación
Evelyn Oña	Data Analyst	EDA y visualización descriptiva
Alisson Manosalvas	Data Steward	Ética, LOPDP y gobernanza de datos

Fecha de elaboración: 28 de junio de 2026

Propósito del Documento

El presente Decision Log documenta, de manera trazable y auditable, las decisiones técnicas, metodológicas y éticas adoptadas a lo largo del ciclo de vida del modelo predictivo de riesgo de pobreza cantonal en Ecuador. Cada entrada describe la decisión tomada, las alternativas evaluadas, su justificación técnica y/o ética, y el rol responsable, con el objetivo de garantizar la reproducibilidad, la gobernanza y la transparencia del proceso de modelado frente a revisores académicos, auditores de gobernanza de datos y futuros mantenedores del sistema.

Registro de Decisiones

DEC-001 · Exclusión de zonas no delimitadas (“El Piedrero” y “Manga del Cura”)	
Fase del Ciclo de Vida	Limpieza de Datos (Data Cleaning)
Descripción de la Decisión	Se excluyó del panel cantonal a las zonas no delimitadas “El Piedrero” y “Manga del Cura” debido a la ausencia estructural y sistemática de registros en las variables de recaudación tributaria y registro mercantil. Esta carencia no responde a un error de captura, sino a la naturaleza administrativa especial de estos territorios, que en conjunto representan menos del 1% del volumen total de observaciones del dataset.
Alternativas Consideradas	• Imputar los nulos con cero, lo que habría subestimado artificialmente la actividad económica real de la zona. • Imputar con el promedio nacional, lo que habría introducido información ficticia en territorios sin cobertura administrativa formal. • Mantener las observaciones como NA dentro del panel, lo que habría obligado a excluirlas en cada modelo individual de forma inconsistente.
Justificación Técnica y Ética	La exclusión definitiva, en lugar de la imputación, se sustenta en el principio de integridad estadística: un nulo estructural (ausencia de la institución que genera el dato) no es comparable a un nulo aleatorio (dato no reportado por error). Imputar valores en este escenario habría generado una falsa señal de cobertura administrativa allí donde, de hecho, no existe. Dado que el volumen afectado es marginal (<1%), la exclusión no compromete la representatividad nacional del modelo ni introduce sesgo de selección significativo.
Responsable(s)	Kevin Delgado (Data Engineer) — validado por Alisson Manosalvas (Data Steward)

DEC-002 · Imputación de Población y VAB 2024 mediante regresión lineal por cantón	
Fase del Ciclo de Vida	Preprocesamiento / Imputación
Descripción de la Decisión	Para completar los valores faltantes de Población y Valor Agregado Bruto (VAB) correspondientes a 2024, se ajustó una regresión lineal independiente para cada uno de los cantones del panel, utilizando la serie histórica 2019-2023 de ese mismo cantón como base de proyección, en lugar de recurrir a un promedio agregado a nivel nacional.
Alternativas Consideradas	• Imputación por la media global nacional, que homogeniza cantones con dinámicas demográficas y productivas completamente distintas. • Forward-fill (arrastrar el último valor observado de 2023), que ignora la tendencia de crecimiento o decrecimiento propia del territorio. • Interpolación lineal calculada sobre el conjunto agregado de cantones, en lugar de a nivel individual.
Justificación Técnica y Ética	Ecuador presenta una alta heterogeneidad territorial: existen cantones en expansión demográfica y económica y otros en franco estancamiento o contracción. Una imputación basada en promedios globales habría “regresado a la media” a todos los cantones por igual, borrando precisamente la señal de trayectoria territorial que el modelo necesita aprender. La regresión por cantón preserva la pendiente histórica individual, manteniendo la coherencia interna de la serie temporal que posteriormente alimenta el componente autoregresivo del modelo final (TS2).
Responsable(s)	Kevin Delgado (Data Engineer) — con validación estadística de Yosslava Garofalo (Data Scientist)

DEC-003 · Conservación de valores atípicos en ventas y recaudación	
Fase del Ciclo de Vida	Limpieza de Datos / EDA
Descripción de la Decisión	Se identificaron valores atípicos en un rango de 8% a 14% de los registros de ventas y recaudación tributaria por cantón. Tras su análisis, el equipo decidió conservarlos sin aplicar winsorización ni eliminación, bajo la premisa de que dichos valores capturan la heterogeneidad económica real del país, y no representan errores de medición.
Alternativas Consideradas	• Winsorización al percentil 95, que habría comprimido artificialmente la dispersión real de cantones con economías altamente concentradas. • Eliminación de outliers mediante la regla del rango intercuartílico (IQR), lo que habría reducido el tamaño muestral en territorios ya escasamente representados. • Transformación logarítmica forzada sobre todas las variables económicas, independientemente de su distribución original.
Justificación Técnica y Ética	En la economía ecuatoriana, varios cantones concentran su actividad productiva en un número reducido de empresas grandes (p. ej. agroindustria o manufactura localizada), lo que produce de forma legítima valores extremos de ventas y recaudación. Suprimir estos registros habría sesgado el modelo hacia una economía “promedio” que no existe en la realidad territorial. El desempeño final del modelo (RMSE = 0.00351; R² = 0.9981) confirma que fue posible lograr una generalización robusta sin necesidad de suprimir esta varianza genuina.
Responsable(s)	Evelyn Oña (Data Analyst) — con revisión de Yosslava Garofalo (Data Scientist)

DEC-004 · Feature Engineering: Log_Población y síntesis del IRS mediante PCA	
Fase del Ciclo de Vida	Ingeniería de Características
Descripción de la Decisión	Se aplicó una transformación logarítmica a la variable Población (Log_Población) para corregir su fuerte asimetría positiva. Adicionalmente, se utilizó Análisis de Componentes Principales (PCA) para sintetizar un conjunto de indicadores socioeconómicos correlacionados en un único Índice de Riesgo Social (IRS).
Alternativas Consideradas	• Estandarización Z-score directa sobre la población sin corrección de asimetría, lo que habría dejado una distribución de cola pesada que distorsiona modelos lineales. • Uso de las variables socioeconómicas crudas sin reducción dimensional, exponiendo al modelo a multicolinealidad severa. • Suma ponderada manual de indicadores, basada en juicio experto, en lugar de un método estadístico no supervisado como PCA.
Justificación Técnica y Ética	La distribución de la población cantonal es altamente asimétrica (pocos cantones muy poblados frente a una mayoría de cantones pequeños); Log_Población estabiliza la varianza y mejora el comportamiento de los modelos lineales y de árbol que dependen de ella. Por su parte, el PCA permite capturar la varianza compartida entre indicadores socioeconómicos correlacionados sin imponer pesos arbitrarios o subjetivos, reduciendo la multicolinealidad y produciendo un IRS más robusto e interpretable como insumo único para el modelo predictivo.
Responsable(s)	Juan Ramos (ML Engineer) — con apoyo metodológico de Yosslava Garofalo (Data Scientist)

DEC-005 · Validación mediante Time Series Split (Train 2019-2023 / Test 2024)	
Fase del Ciclo de Vida	Validación y Experimentación
Descripción de la Decisión	La estrategia de validación adoptada fue una partición temporal estricta: entrenamiento con el período 2019-2023 y prueba exclusivamente sobre 2024, en lugar de una validación cruzada aleatoria (K-fold) sobre el panel completo.
Alternativas Consideradas	• K-fold cruzado aleatorio (5-fold) sobre todas las observaciones, mezclando años pasados y futuros entre los conjuntos de entrenamiento y prueba. • Validación leave-one-canton-out, que evalúa la capacidad de generalización entre territorios pero no la capacidad de proyección temporal, que es el objetivo real del modelo.
Justificación Técnica y Ética	Un K-fold aleatorio sobre datos de panel temporal permite que el modelo “vea” información de 2024 durante el entrenamiento si esa observación cae en un fold de entrenamiento, generando data leakage y métricas de desempeño infladas artificialmente. El Time Series Split replica fielmente el escenario real de uso del modelo: predecir un año futuro (2024) utilizando únicamente información disponible hasta el período anterior. Esta decisión es la que otorga validez al RMSE de 0.00351 reportado, al garantizar que dicha métrica refleja capacidad de proyección genuina y no memorización del conjunto de entrenamiento.
Responsable(s)	Yosslava Garofalo (Data Scientist) — supervisado por Juan Ramos (ML Engineer)

DEC-006 · Selección del modelo final: TS2 — AR(1) + Tendencia Lineal	
Fase del Ciclo de Vida	Selección de Modelo
Descripción de la Decisión	Tras comparar múltiples arquitecturas, se seleccionó como modelo final el TS2 (componente autoregresivo de orden 1 combinado con una tendencia lineal), que obtuvo un RMSE de 0.00351 y un R² de 0.9981 sobre el conjunto de prueba 2024, superando a los modelos de ensamble evaluados (XGBoost y Random Forest).
Alternativas Consideradas	• XGBoost, que mostró mayor capacidad de capturar interacciones no lineales entre variables exógenas, pero un RMSE superior al no modelar explícitamente la autocorrelación temporal del IRS. • Random Forest, con un comportamiento similar a XGBoost: buen ajuste transversal entre cantones, pero menor capacidad de proyección de la inercia histórica de cada serie individual. • Modelos de ensamble híbridos (AR + boosting sobre residuos), descartados en esta iteración por el riesgo de sobreajuste dado el tamaño limitado del panel (5 años de historia).
Justificación Técnica y Ética	El Índice de Riesgo Social presenta una fuerte inercia histórica: el valor de un cantón en el año t depende en gran medida de su propio valor en t-1, más que de la combinación no lineal de variables exógenas que capturan los modelos de ensamble. Un componente autoregresivo explícito modela directamente esta dependencia temporal, mientras que XGBoost y Random Forest, al ser modelos de corte transversal por diseño, requieren features adicionales (lags, ventanas) para aproximar ese mismo comportamiento, con menor eficiencia. La parsimonia del AR(1)+Tendencia también reduce el riesgo de sobreajuste frente a un panel relativamente corto, lo cual se refleja directamente en su menor RMSE y mayor R² sobre el conjunto de prueba 2024.
Responsable(s)	Juan Ramos (ML Engineer) — validado por Yosslava Garofalo (Data Scientist)

DEC-007 · Creación del Índice de Resiliencia Local (IRL) como KPI de negocio	
Fase del Ciclo de Vida	Despliegue / Traducción a Producto
Descripción de la Decisión	Se diseñó el Índice de Resiliencia Local (IRL) como una capa de traducción del IRS hacia un KPI de negocio interpretable, estructurado como un semáforo de priorización presupuestaria, donde la regla de decisión establece que $IRL \leq 0$ activa una bandera de Intervención prioritaria.
Alternativas Consideradas	- Exponer directamente el IRS (componente principal del PCA) sin transformación, lo cual carece de un punto de corte intuitivo para tomadores de decisión no técnicos. - Utilizar un ranking de percentiles relativos entre cantones sin un umbral fijo, lo que dificulta la planificación presupuestaria multianual al carecer de un punto de referencia estable en el tiempo.
Justificación Técnica y Ética	Un índice estadístico como el IRS, expresado en unidades de componente principal, no es directamente interpretable por funcionarios de planificación o asignación presupuestaria. El IRL traduce esa salida en una regla de decisión binaria-semafórica (Intervención / No Intervención) con un umbral fijo y defendible ($IRL \leq 0$), permitiendo que el modelo se integre en procesos reales de gobernanza presupuestaria sin requerir conocimiento técnico del PCA o del modelo subyacente. Este diseño cierra el ciclo entre la capa analítica y la capa de decisión, que es el objetivo final del proyecto integrador.
Responsable(s)	Juan Ramos (ML Engineer) y Alisson Manosalvas (Data Steward) — con validación de negocio del equipo completo

DEC-008 · Documentación del Sesgo de Cobertura Administrativa (Ética y LOPDP)	
Fase del Ciclo de Vida	Ética y Gobernanza de Datos
Descripción de la Decisión	Se documentó explícitamente, como parte del entregable final, la existencia de un Sesgo de Cobertura Administrativa: el modelo tiende a subestimar el riesgo real en cantones con alta informalidad económica, dado que las fuentes administrativas utilizadas (recaudación tributaria, registro mercantil) no capturan la actividad económica informal de esos territorios.
Alternativas Consideradas	• Omitir esta limitación del reporte final, presentando el modelo como una medición completa y neutral del riesgo cantonal. • Aplicar un factor de corrección no validado estadísticamente para “compensar” la informalidad estimada, lo cual habría introducido un sesgo nuevo y no auditable en lugar de corregir el original.
Justificación Técnica y Ética	Bajo los principios de la Ley Orgánica de Protección de Datos Personales (LOPDP) y de gobernanza responsable de datos, todo modelo que informe decisiones de asignación de recursos públicos tiene la obligación de documentar de forma transparente sus limitaciones de cobertura y representatividad, especialmente cuando estas pueden afectar de forma desigual a poblaciones vulnerables. Un cantón con alta informalidad económica podría aparecer como “menos riesgoso” de lo que realmente es, derivando en una asignación presupuestaria inequitativa si esta limitación no se comunica explícitamente a los tomadores de decisión. Se priorizó la transparencia documentada sobre una corrección estadística no validada, evitando sustituir un sesgo conocido por otro no auditado.
Responsable(s)	Alisson Manosalvas (Data Steward) — con respaldo y revisión de todo el equipo del proyecto

Retrospectiva Individual

Reflexión individual de cada integrante sobre la decisión metodológica que modificaría si el proyecto iniciara nuevamente desde el Sprint 1, con base en el aprendizaje acumulado durante el ciclo de vida del modelo.

Juan Ramos — Machine Learning Engineer

Si el Sprint 1 comenzara hoy, incorporaría desde el diseño inicial intervalos de confianza (vía bootstrap) sobre las predicciones del componente AR(1), en lugar de reportar únicamente el estimado puntual del IRS; esto permitiría comunicar la incertidumbre de la proyección junto al RMSE y evitaría que el IRL se interprete como un valor determinístico.

Kevin Delgado — Data Engineer

Automatizaría desde el primer sprint un pipeline de validación de esquema y detección de nulos estructurales (data quality gate), en lugar de identificar manualmente casos como El Piedrero y Manga del Cura ya avanzado el proyecto; esto habría adelantado la decisión de exclusión y reducido el retrabajo en etapas posteriores de imputación.

Yosslava Garofalo — Data Scientist

Evaluaría desde el Sprint 1 un modelo híbrido que combine el componente AR(1) con un módulo de boosting sobre los residuos, en lugar de comparar AR(1), XGBoost y Random Forest como alternativas mutuamente excluyentes; esto podría capturar tanto la inercia histórica del IRS como posibles interacciones no lineales residuales no explicadas por la tendencia lineal.

Evelyn Oña — Data Analyst

Implementaría desde la fase de EDA un dashboard de monitoreo continuo de outliers por cantón y por año, en lugar de un análisis exploratorio estático de un solo corte; esto permitiría distinguir más temprano entre outliers estructurales persistentes (economías concentradas) y outliers puntuales atribuibles a shocks coyunturales.

Alisson Manosalvas — Data Steward

Establecería el marco de evaluación del Sesgo de Cobertura Administrativa como un requisito de entrada (gate de gobernanza) previo al entrenamiento del modelo, y no como una documentación posterior a la selección del modelo final; esto habría permitido contrastar desde el inicio qué variables alternativas podrían aproximar la informalidad económica cantonal.