

DOCUMENTO INTEGRADOR FINAL

Predicción de Riesgo de Pobreza por Cantón en Ecuador

Índice de Resiliencia Local (IRL) · 219 Cantones · 2019–2026

Integrante	Rol	Responsabilidad Principal
Juan Ramos	Machine Learning Engineer	Automatización, modelos y arquitectura TS2
Kevin Delgado	Data Engineer	ETL, limpieza y preprocesamiento
Yosslava Garofalo	Data Scientist	Experimentación, métricas y validación
Evelyn Oña	Data Analyst	EDA, outliers y Dashboard Power BI
Alisson Manosalvas	Data Steward	Ética, LOPDP y gobernanza de datos

Carrera de Ciencia de Datos · PUCE
Docente: Kevin Rojas Satian
Semana 7 — Cierre del Curso · Junio 2026

1 RESUMEN EJECUTIVO

Problema. Ecuador carece de métricas socioeconómicas cantonales actualizadas entre períodos censales. Esta ausencia impide que los Gobiernos Autónomos Descentralizados (GAD) Provinciales y el Ministerio de Desarrollo e Inclusión Social (MIDESO) asignen presupuestos con criterio territorial y horizonte predictivo. Sin indicadores de alerta temprana, la intervención pública llega tarde, con mayor costo y menor impacto.

Propuesta. El presente proyecto desarrolló un sistema predictivo que genera el **Índice de Resiliencia Local (IRL)** — un semáforo cantonal de priorización presupuestaria. El IRL se calcula como la diferencia entre la variación real per cápita del cantón y el promedio nacional del mismo período. Un valor $IRL \leq 0$ activa automáticamente una señal de intervención prioritaria, traduciendo el Índice de Riesgo Socioeconómico (IRS) en una regla de decisión directamente interpretable por funcionarios públicos sin formación técnica en aprendizaje automático.

Resultado. El modelo ganador **TS2 — AR(1) + Tendencia Lineal** alcanzó un **RMSE de 0.00351** y **R² de 0.9981** sobre el conjunto de prueba 2024, superando a todos los baselines y modelos de ensamble evaluados. Las proyecciones para 2025–2026 identifican **99 cantones con IRS ≥ 0.99** (alta vulnerabilidad estructural), con Caluma, Balao y Cevallos encabezando la lista de territorios que requieren atención prioritaria. El sistema cubre los 219 cantones del Ecuador continental e insular, y sus resultados están disponibles a través de un Dashboard Power BI interactivo con proyecciones hasta 2026.

2 METODOLOGÍA Y CICLO DE VIDA DEL MODELO

2.1 Fases del Proyecto

Fase 1 — Ingesta y fuentes de datos. El proyecto integró microdatos provenientes de cuatro instituciones públicas ecuatorianas: el Instituto Nacional de Estadística y Censos (INEC), el Banco Central del Ecuador (BCE), el Servicio de Rentas Internas (SRI) y la Superintendencia de Compañías, Valores y Seguros (SCVS). Las series cubren el período 2019–2024 y abarcan variables de empleo (total, masculino y femenino), salarios promedio, ventas locales, recaudación tributaria, valor agregado bruto (VAB) per cápita, variación interanual real y registro de nuevas compañías. El dataset final —tras limpieza— consolidó **1,326 registros para 219 cantones** con 11 variables, sin ningún valor nulo.

Fase 2 — ETL y Limpieza (Kevin Delgado, Data Engineer). La ingesta bruta fue procesada mediante un pipeline documentado en Google Colab. Se realizó una revisión exhaustiva de nulos por columna, identificando dos categorías de datos faltantes: nulos *estructurales* (El Piedrero y Manga del Cura, excluidos por carecer de institucionalidad administrativa formal) y nulos *temporales* (año 2024 para Población y VAB), resueltos mediante regresión lineal individual por cantón para preservar la trayectoria histórica de cada territorio.

Fase 3 — Análisis Exploratorio y Feature Engineering (Evelyn Oña / Juan Ramos). El EDA detectó distribuciones asimétricas en Población (alta concentración en pocos cantones grandes), lo que motivó la aplicación de transformación logarítmica (Log_Población). Adicionalmente, se aplicó **Análisis de Componentes Principales (PCA)** sobre un conjunto de indicadores socioeconómicos correlacionados, sintetizando el **Índice de Riesgo Socioeconómico (IRS)** como variable objetivo del modelo. El análisis de outliers confirmó que entre el 8% y el 14% de los registros de ventas y recaudación presentan valores atípicos, los cuales fueron conservados por reflejar la heterogeneidad

económica legítima del territorio ecuatoriano.

Fase 4 — Modelado Predictivo (Juan Ramos / Yoslava Garofalo). Se diseñó una arquitectura predictiva de tres modelos complementarios: un modelo de series de tiempo con componente autoregresivo de orden 1 (TS2-AR(1)), un Random Forest y un Gradient Boosting (XGBoost). La validación adoptó un **Time Series Split estricto**: entrenamiento 2019–2023, prueba exclusivamente en 2024, garantizando la ausencia de *data leakage* temporal. El modelo TS2 fue seleccionado como ganador al capturar la alta inercia del IRS a través del componente lag-1.

Fase 5 — Despliegue y Producto (Evelyn Oña). Los resultados se materializaron en un Dashboard Power BI con tres páginas: Panorama General (mapa coroplético e IRL por cantón), Análisis Histórico 2019–2024 (tendencias y comparativas interanuales) y Proyecciones 2025–2026 (semáforo de intervención prioritaria). El archivo fuente estructurado en cuatro hojas Excel permite actualizar el dashboard al publicarse nuevos datos del INEC.

2.2 Roles, Hitos y Entregables

Integrante / Rol	Hito Principal	Entregable
Kevin Delgado Data Engineer	Pipeline ETL con detección y resolución de nulos estructurales y temporales	Notebook Colab · dataset_limpio_exportado.xlsx · 1,326 registros
Juan Ramos ML Engineer	Arquitectura TS2-AR(1), Feature Engineering PCA/Log_Población y proyecciones 2025–2026	Pipeline ML · predicciones_IRS_2025_2026.xlsx · Decision Log DEC-001/004/006/007
Yoslava Garofalo Data Scientist	Validación Time Series Split · comparativa de 5 modelos · análisis de fairness por grupo	Tabla comparativa de métricas · Recall por grupo sensible · DEC-005/006
Evelyn Oña Data Analyst	EDA completo con análisis de outliers por cantón y año · Dashboard Power BI 3 páginas	Informe EDA · dashboard_IRL_PowerBI_v2.xlsx · DEC-003
Alisson Manosalvas Data Steward	Checklist Ético LOPDP (8/12 pleno, 4/12 parcial) · documentación DEC-008	Model Card · Checklist Ético · DEC-002/008

Tabla 1. Matriz de roles, hitos y entregables del equipo.

2.3 Decisiones Clave del Ciclo de Vida (Decision Log)

El ciclo de vida del modelo se documenta en ocho decisiones técnicas y éticas trazables, cada una con sus alternativas evaluadas, justificación y responsable designado:

ID	Fase	Decisión	Justificación técnica / ética clave
DEC-001	Limpieza	Exclusión de El Piedrero y Manga del Cura	Nulos estructurales (ausencia institucional), no aleatorios. Volumen < 1%.
DEC-002	Imputación	Regresión lineal individual por cantón para Población y VAB 2024	Preserva la pendiente histórica territorial frente a medias globales que borrarían la señal.
DEC-003	EDA	Conservación de outliers (8–14%) en ventas y recaudación	Reflejan heterogeneidad económica real (agroindustria concentrada). RMSE final confirma robustez.

DEC-004	Feature Eng.	Log_Población + PCA para sintetizar IRS	Corrige asimetría de Población; PCA elimina multicolinealidad sin pesos subjetivos.
DEC-005	Validación	Time Series Split: train 2019–2023, test 2024	Elimina data leakage temporal. Las métricas reportadas son de proyección genuina.
DEC-006	Selección	TS2-AR(1)+Tendencia como modelo final	El IRS tiene alta inercia: el lag-1 explica más varianza que las interacciones de RF/GBR.
DEC-007	Producto	IRL = semáforo de intervención presupuestaria (umbral $IRL \leq 0$)	Traduce la salida estadística (PCA) en una regla binaria interpretable por no técnicos.
DEC-008	Ética	Documentación del Sesgo de Cobertura Administrativa	Transparencia sobre subestimación del riesgo en cantones con alta informalidad económica.

Tabla 2. Resumen del Decision Log (DEC-001 a DEC-008).

3

RESULTADOS Y EVALUACIÓN

3.1

Tabla Comparativa de Modelos

La estrategia de validación temporal garantiza que las métricas reportadas reflejan capacidad de proyección genuina y no memorización del conjunto de entrenamiento. Los cinco modelos evaluados se presentan a continuación:

Modelo	RMSE ↓	MAE ↓	R ² ↑	Observación
TS1 — Tendencia Lineal (baseline)	0.08129	0.02012	0.0051	No captura autocorrelación temporal
TS2 — AR(1) + Tendencia ★ GANADOR	0.00351	0.00190	0.9981	Captura inercia histórica del IRS
TS3 — AR(2) + Tendencia	0.00811	0.00173	0.9901	Más parámetros, menos datos de entrenamiento
Random Forest (300 árboles, depth=8)	~0.012	~0.008	~0.978	Útil para análisis de variables e importancia
Gradient Boosting / XGBoost (400 iter.)	~0.014	~0.009	~0.971	Optimización iterativa; no supera inercia AR(1)

Tabla 3. Comparativa de modelos — validación temporal (train 2019–2023, test 2024). ★ Modelo seleccionado.

3.2

Análisis de Fairness y Equidad

El análisis de equidad evaluó el desempeño del modelo TS2 desagregado por tipo de cantón, como aproximación a grupos sensibles en el dominio territorial ecuatoriano. Se verificó que el modelo mantiene un **Recall ≥ 94% en todos los grupos**, sin evidencia de discriminación sistemática hacia ningún segmento territorial:

Grupo	Descripción	Recall (test 2024)	Observación
Urbano grande	Cantones con > 100,000 hab. (Guayaquil, Quito, Cuenca)	≥ 98%	Dominan la varianza del IRS
Urbano mediano	Cantones de 30,000 – 100,000 hab.	≥ 96%	Comportamiento estable
Rural pequeño	Cantones con < 30,000 hab. (mayoría del panel)	≥ 94%	Mayor variabilidad pero dentro del umbral
Amazónico	Cantones de la región amazónica	≥ 94%	Riesgo de sesgo por informalidad — documentado en DEC-008
Insular	Cantones de Galápagos	≥ 95%	Economía turística diferenciada

Tabla 4. Desempeño del modelo TS2-AR(1) por grupo sensible (tipo de cantón).

3.3

Simulación de Impacto — IRL como Instrumento de Política Pública

El **Índice de Resiliencia Local (IRL)** opera como traductor entre la salida estadística del modelo y la capa de decisión presupuestaria. Su fórmula es:

IRL = Variación real per cápita del cantón – Promedio nacional del mismo período

La regla de decisión establece tres categorías de alerta: **IRL > 0** indica que el cantón crece por encima del promedio nacional (prioridad baja); **IRL ≈ 0** requiere monitoreo continuo; y **IRL ≤ 0** activa una señal de intervención prioritaria, orientando la asignación presupuestaria de los GAD Provinciales y el MIDESO hacia los territorios con mayor rezago relativo. Esta focalización temprana reduce el costo de la intervención social frente a escenarios de no actuación, donde el deterioro estructural es más costoso de revertir.

Las proyecciones 2025–2026 del modelo TS2-AR(1) identifican: **99 cantones con IRS ≥ 0.99** (alta vulnerabilidad estructural), **117 cantones con IRS 0.93–0.99** (riesgo medio) y **3 cantones con IRS < 0.93** (baja vulnerabilidad). Los cantones Caluma, Balao, Cevallos, Atahualpa y Alfredo Baquerizo Moreno encabezan la lista de mayor riesgo proyectado para 2025.

4

LECCIONES APRENDIDAS Y PRÓXIMOS PASOS

4.1 Retrospectiva del Equipo

La retrospectiva estructurada del equipo, siguiendo el formato del Decision Log, produjo cinco reflexiones individuales sobre decisiones que cada integrante tomaría de forma diferente si el proyecto comenzara desde el Sprint 1:

Juan Ramos — ML Engineer	Incorporaría desde el diseño inicial intervalos de confianza vía bootstrap sobre las predicciones del componente AR(1), en lugar de reportar únicamente el estimado puntual del IRS. Esto permitiría comunicar la incertidumbre de la proyección junto al RMSE y evitaría que el IRL se interprete como un valor determinístico cuando la naturaleza del modelo es probabilística.
Kevin Delgado — Data Engineer	Automatizaría desde el primer sprint un pipeline de validación de esquema y detección de nulos estructurales (data quality gate), en lugar de identificar manualmente los casos de El Piedrero y Manga del Cura ya avanzado el proyecto. Un gate automatizado habría adelantado la decisión de exclusión y reducido el retrabajo en etapas posteriores de imputación.
Yosslava Garofalo — Data Scientist	Evaluaría desde el Sprint 1 un modelo híbrido que combine el componente AR(1) con un módulo de boosting sobre los residuos, en lugar de comparar AR(1), XGBoost y Random Forest como alternativas mutuamente excluyentes. Un modelo híbrido podría capturar tanto la inercia histórica del IRS como posibles interacciones no lineales residuales no explicadas por la tendencia lineal.
Evelyn Oña — Data Analyst	Implementaría desde la fase de EDA un dashboard de monitoreo continuo de outliers por cantón y año, en lugar de un análisis exploratorio estático de un solo corte. Esto permitiría distinguir más temprano entre outliers estructurales persistentes (economías concentradas) y outliers puntuales atribuibles a shocks coyunturales externos.

Alisson Manosalvas
— Data Steward

Establecería el marco de evaluación del Sesgo de Cobertura Administrativa como un requisito de entrada previo al entrenamiento del modelo, y no como una documentación posterior a la selección del modelo final. Esto habría permitido contrastar desde el inicio qué variables alternativas podrían aproximar la informalidad económica cantonal.

4.2 Limitaciones del Modelo (Model Card §6)

El Model Card del proyecto documenta seis limitaciones que deben considerarse al interpretar los resultados y antes de escalar el sistema a producción:

Limitación	Descripción e implicación
Ventana temporal corta	El modelo fue entrenado con cinco años de historia (2019–2024). Series más largas mejorarían la estimación de tendencias y reducirían la varianza del componente AR(1).
Ausencia de shocks externos	El modelo no incorpora variables exógenas de shocks (crisis económicas, fenómenos naturales, pandemia como factor explícito). Los picos de 2020 se absorben en la tendencia lineal.
IRS no desagregado por género	Las variables de empleo por sexo fueron utilizadas únicamente como indicadores auxiliares de fairness, no como features predictivos, lo que limita la capacidad de identificar brechas de género a nivel cantonal.
Exclusión de dos cantones	El Piedrero y Manga del Cura (< 1% del total) no cuentan con predicciones, dado que sus nulos estructurales impiden una imputación metodológicamente válida.
Ausencia de variables educativas	Indicadores de escolaridad, cobertura educativa y tasas de analfabetismo no fueron incorporados por no estar disponibles con el desglose cantonal anual requerido.
Sesgo de Cobertura Administrativa	Las fuentes utilizadas (SRI, SCVS) no capturan la economía informal. Cantones con alta informalidad económica —especialmente amazónicos y fronterizos— pueden aparecer con IRS subvalorado, derivando en una subestimación del riesgo real (DEC-008).

Tabla 5. Limitaciones documentadas en el Model Card §6.

4.3 Cumplimiento de la LOPDP

La evaluación ética fue realizada por Alisson Manosalvas (Data Steward) con revisión del equipo completo, aplicando los principios de la Ley Orgánica de Protección de Datos Personales del Ecuador (R.O. 459, 26 de mayo de 2021). El proyecto opera exclusivamente sobre registros administrativos agregados a nivel cantonal —no procesa datos personales de individuos—, lo que reduce sustancialmente el riesgo ético inherente al modelo.

Principio LOPDP	Estado	Evidencia / Respuesta del proyecto
Licitud y finalidad	Cumple	Finalidad documentada en ML Canvas y Model Card §5: priorización de política pública cantonal.
Minimización de datos	Cumple	Pipeline EDA eliminó columnas redundantes. TS2 usa únicamente IRS_lag1 y tendencia temporal.
Sin decisión automática sobre personas	Cumple	El modelo genera índices territoriales. La asignación presupuestaria final recae en funcionarios humanos.

Transparencia del modelo	Cumple	Model Card §1 y §5 describe el modelo en lenguaje no técnico, con ecuación y aclaraciones.
Responsable del tratamiento	Cumple	Alisson Manosalvas designada Data Steward en la RACI del equipo.
Limitaciones documentadas	Cumple	6 limitaciones registradas en Model Card §6, con acción de mejora en Decision Log.
Sesgos del dataset documentados	Cumple	DEC-008 documenta el Sesgo de Cobertura Administrativa con rigor equivalente a un sesgo real.
Fairness por grupos sensibles	Cumple	Recall $\geq$ 94% en los cinco grupos cantonales. Desagregación de género: deuda técnica para el siguiente sprint.
Variables proxy de características protegidas	Parcial	Log_Población actúa como proxy del nivel de desarrollo urbano — documentado explícitamente en Model Card §7.
Revisión humana formal	Parcial	Cantones con IRS 0.80–0.89 remitidos a revisión por analista. Mecanismo formal pendiente de implementación.
Derechos ARCO+ territoriales	Parcial	El modelo AR(1) es auditable (coeficientes visibles). No existe mecanismo formal de apelación en el prototipo.
Conservación y descarte de datos	Parcial	Política propuesta: datos crudos hasta publicación INEC 2025; predicciones hasta actualización anual. No formalizada en repositorio.

Tabla 6. Evaluación de cumplimiento LOPDP — 8/12 Cumple · 4/12 Parcial · 0/12 Incumplido.

4.4 Próximos Pasos para Producción Real

Para escalar el sistema hacia una herramienta de gobernanza presupuestaria real en Ecuador, el equipo propone las siguientes acciones prioritarias, ordenadas por impacto esperado:

Acción	Descripción
Intervalos de confianza bootstrap	Añadir bandas de incertidumbre al IRL predicho, permitiendo comunicar el riesgo con margen de error explícito ante tomadores de decisión.
Integración de datos INEC 2025	Reentrenar el modelo con el año adicional de historia al publicarse los microdatos, mejorando la estabilidad del componente AR(1).
Incorporar variables de informalidad	Explorar proxies de economía informal (ENEMDU, transferencias BDH) para reducir el Sesgo de Cobertura Administrativa en cantones amazónicos.
Desagregación del IRS por género	Incluir indicadores de brecha salarial y empleo femenino como features predictivos, pendiente identificado en el análisis de fairness.
Mecanismo formal de apelación ARCO+	Implementar canal para que representantes territoriales soliciten la explicación técnica del IRS de su cantón, cerrando el cumplimiento parcial de la LOPDP.
API REST para consumo institucional	Desplegar el modelo como servicio web consumible por los sistemas de planificación de los GAD Provinciales, con autenticación y control de versiones.

Tabla 7. Próximos pasos priorizados para llevar el modelo a producción real en Ecuador.